Лабораторная работа №8

Генерация и интерполяция в латентном пространстве

Вариант 3: VAE d=8 → d=2

Власюк Данил Витальевич
Группа Т26ИИКТ-МИК11
Дисциплина «Искусственный интеллект в креативных технологиях»

Фактическое выполнение: 29 октября 2026 года, Engee 26.10.2-H2, Python на CPU. Дата/время Python: 2026-10-29T08:36:47.939239+00:00

Цель: обучить VAE на синтетических сценах, получить сэмплы и промежуточные изображения, оценить влияние размера латентного вектора на четыре показателя и объяснить диагностику активных осей.

Основной эксперимент выполнен в Engee, как требует приложенная методичка. Подготовлен отдельный ноутбук LR08_3.ngscript; Julia вызывает Python 3.11. Установлен CPU PyTorch 2.4.1. Внешние веса, фотографии и персональные данные не используются.

1. Гипотеза и протокол до запуска

Вариант 3, набор disc: янтарный диск на градиентном фоне, факторы x, y и радиус. A: VAE d=8; B: VAE d=2. Единственный изменяемый параметр - размер латентного вектора. beta=1, warmup=10 эпох, всего 30 эпох, Adam lr=0.002, batch=128, float32, линейная интерполяция, tau=1. Данные: 4096 train и 1024 test, data seed7. Seed обучения101-105. Вычисления на CPU в Engee, 4 потока (не более доступных), как в библиотеке.

Гипотеза: слишком узкое представление d=2 ухудшит реконструкцию более чем на 1 дБ и среднее линейное R2 факторов более чем на 0.05. Ожидаем, что информация о радиусе теряется сильнее, чем положение; это проверяется отдельно по R2_x, R2_y, R2_radius, а не только счётом факторов. Направление изменения интерполяции и близости сэмплов заранее не гарантируется. Меньшее d не обязательно ухудшает все метрики.

Допуски до запуска: реконструкция, интерполяция, сэмплы ±1.0 дБ; R2 ±0.05. Рост выше допуска - улучшение данного показателя, падение - ухудшение, внутри - нейтрально. |Δ|>2s_A считается отдельно как эвристика разброса seed, не p-value. Для варианта3 все четыре метрики могут меняться; неизменяемой контрольной метрики нет.

200 пар с seed11, t=0.25/0.5/0.75; истинный эталон - рендер взвешенных факторов. 256 сэмплов из N(0,I), seed1000+seed обучения; метрика сэмплов не оценивает разнообразие. Для диагностики активна ось с mean KL>0.05 нат. Сравним также AE beta=0 с VAE beta=1/8 и проверку схлопывания без warmup из полного демо. Три непрерывных фактора - ориентир; для конечного дискретного рендера универсальная теорема о минимальном d не утверждается.

Записано: 2026-10-29T11:31:25.111786+03:00

Гипотеза и SHA-256 записаны в data/hypothesis.md и reports/pre_run_record.json до обучения. Основная таблица получена неизменённой функцией V.variant_summary(3).

2. VAE, данные и воспроизводимость

Параметр	Фактическое значение
Среда	Engee 26.10.2-H2; Julia 1.12.6; Python 3.11.11 (main, Mar 17 2025, 21:02:09) [Clang 20.1.0]
Версии	PyTorch 2.4.1+cpu; NumPy 2.1.3; CPU; threads=4; CUDA=False
Набор	disc: 4096 train, 1024 test; RGB 32×32; data seed7; x/y/радиус
A / B	{'d': 8, 'beta': 1.0, 'interp': 'lin', 'temp': 1.0, 'epochs': 30} {'d': 2, 'beta': 1.0, 'interp': 'lin', 'temp': 1.0, 'epochs': 30}
Обучение	30 эпох, 960 обновлений; Adam lr=0.002; batch128; warmup10; seed101-105
Оценка	200 пар (seed11), t=0.25/0.5/0.75; 256 сэмплов N(0,I); seed1000+seed обучения

Кодировщик свёрточной сети выдаёт μ и log σ². При обучении z=μ+exp(0,5 log σ²)·ε, ε~N(0,I). Декодер восстанавливает RGB. Потери на изображение: сумма квадратов ошибок по пикселям + β·KL(q(z|x)||N(0,I)). Это сумма, а не средняя MSE по 3072 пикселям; изменение нормировки меняло бы относительный вес β.

KL одной оси: -0,5·(1+log σ²-μ²-σ²). Разогрев линейно увеличивает вес KL до β за первые 10 эпох. Для оценки реконструкции используется μ, без случайного шума; при β=0 обучение также декодирует μ и соответствует обычному AE в этой библиотеке.

Сначала полностью выполнен lab08_demo.py: β=1/8, диагностика AE/VAE и схлопывания без warmup. Затем выполнен вариант3; кэш повторно использует уже обученные d=8, β=1. Собственный код лишь сохраняет метрики, ошибки и латентные массивы; учебные исходники не изменены. run_lr08.py - служебный пакетный прогон всех шести вариантов, он не требуется для индивидуального варианта3.

3. Четыре метрики и практический эффект

Средние и выборочный s_A (ddof=1) по seed101-105. Реконструкция - среднее PSNR по 1024 test-сценам. Интерполяция - среднее по 200 парам и трём t относительно рендера взвешенных факторов. Сэмплы - PSNR ближайшей test-сцены для 256 генераций. R^2 - среднее по трём факторам, линейная регрессия обучена на train, проверена на test.

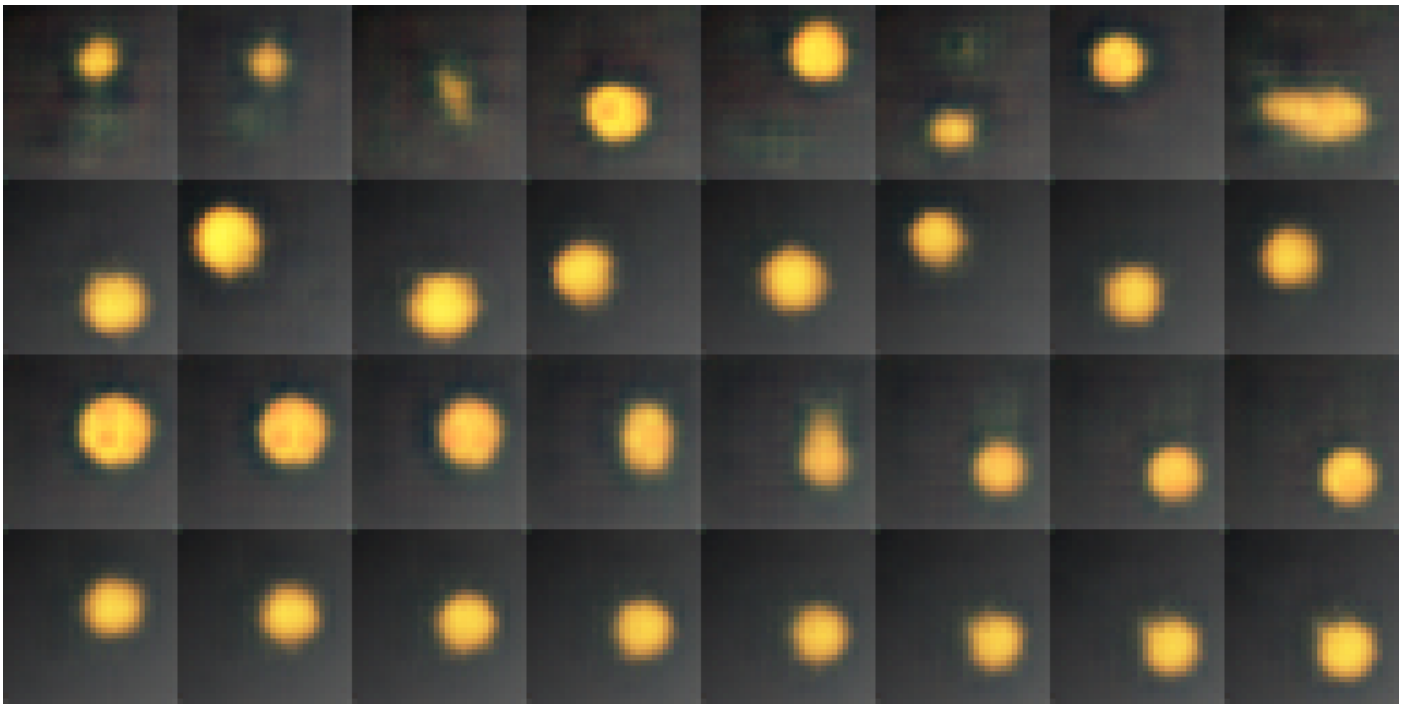
Метрика	A	s_A	B	Δ	|Δ|/s	>2s
recon	26.37189	0.61395	23.22424	-3.14766	5.13	да
interp	22.55258	0.48468	22.97955	+0.42697	0.88	нет
sample	23.24185	0.55578	24.46666	+1.22481	2.20	да
r2	0.89948	0.02195	0.64782	-0.25167	11.46	да

Метрика	Допуск	Класс	2s и допуск расходятся
recon	1.00000	ухудшение	нет
interp	1.00000	нейтрально	нет
sample	1.00000	улучшение	нет
r2	0.05000	ухудшение	нет

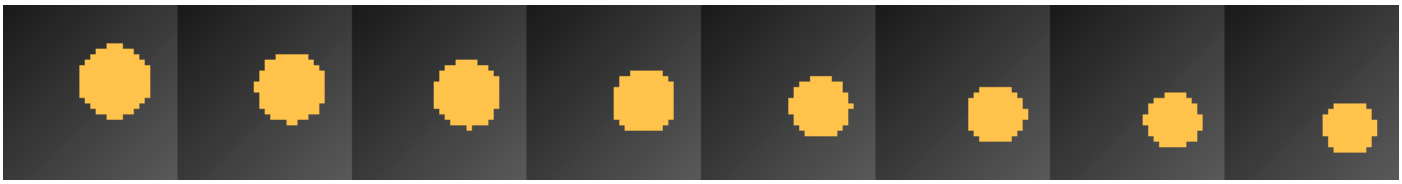
Рост PSNR сэмплов показывает близость к test-сценам, но не разнообразие. Высокий R^2 не доказывает независимости или интерпретируемости отдельных осей. Критерий 2s - учебная эвристика относительно разброса seed, не p-value и не формальное доказательство статистической значимости.

4. Сэмплы и интерполяция

Seed101. Строки сверху вниз: 8 сэмплов A из N(0,I); 8 сэмплов B; линейный путь A; линейный путь B между test-сценами 0 и2. d различается, поэтому одинаковый seed задаёт генераторы, но не одинаковую форму начального тензора. Лист содержит t=0,1/7,…,1; метрика интерполяции измерена отдельно в t=0,25/0,5/0,75. Изображения 32×32 увеличены NEAREST.



Истинный путь: рендер взвешенных факторов x/y/радиус той же пары.



В сэмплах A (первая строка) радиус и яркость сильно различаются: есть слабые маленькие пятна, а у последнего примера видны несколько слившихся ярких областей. В B (вторая строка) получились более одинаковые округлые диски с разными положениями, но меньшей видимой вариативностью радиуса. Это согласуется с улучшением метрики ближайшего соседа без гарантии разнообразия.

На интерполяционных рядах A/B диск постепенно смещается преимущественно вниз и немного вправо. Явной пары раздельных дисков в выбранном пути не видно, но границы размыты. В A радиус меняется, отдельные промежуточные пятна вытянуты; в B форма более однотипна и радиус почти постоянен, тогда как истинный путь показывает его уменьшение. Поэтому требование о плавном восстановлении положения и радиуса выполнено частично.

Осмотр относится к одной паре test-сцен 0 и2 и seed101. Визуальный лист имеет 8 t с шагом 1/7; численная метрика интерполяции рассчитана отдельно на 200 парах и t=0,25/0,5/0,75. По одному листу нельзя оценивать всё распределение сэмплов или доказывать полную потерю фактора.

5. Активные оси и факторы сцены

Режим	seed	d	Активные оси	std μ по осям
A	101	8	7	1.032; 0.967; 0.443; 1.030; 0.230; 0.425; 1.022; 0.982
B	101	2	2	0.983; 1.021
A	102	8	5	1.000; 1.078; 1.042; 0.121; 0.043; 0.934; 0.929; 0.040
B	102	2	2	1.041; 1.043
A	103	8	8	0.948; 1.049; 0.608; 0.927; 0.949; 0.980; 1.004; 0.346
B	103	2	2	1.032; 1.065
A	104	8	6	1.017; 0.689; 0.995; 1.029; 0.075; 0.058; 0.794; 1.043
B	104	2	2	1.032; 1.077
A	105	8	7	0.943; 1.034; 0.988; 0.996; 0.999; 0.714; 0.120; 0.703
B	105	2	2	1.043; 1.008

Активная ось: средний KL по test >0,05 нат; это заданная операционная диагностика. Полные KL по осям сохранены в diagnostic.json. Разброс μ - отдельная характеристика и не заменяет KL.

Режим	Средний R^2_x	Средний R^2_y	Средний R^2_radius
A	0.88508	0.86937	0.94401
B	0.97044	0.97627	-0.00325

Режим A: активные оси по seed101-105: 7/8, 5/8, 8/8, 6/8, 7/8.

Режим B: активные оси по seed101-105: 2/2, 2/2, 2/2, 2/2, 2/2.

По факторам сцены (средние R^2 по пяти seed): r2_x: A=0.88508, B=0.97044, Δ=+0.08536; r2_y: A=0.86937, B=0.97627, Δ=+0.10690; r2_radius: A=0.94401, B=-0.00325, Δ=-0.94726.

Наибольшее падение линейной восстанавливаемости имеет радиус. Это согласуется с ожиданием о потере информации о радиусе.

R^2 измеряет линейное восстановление факторов, а не всю доступную информацию. Низкий R^2 радиуса не доказывает его полного отсутствия в нелинейном коде. Активные оси не обязательно совпадают с независимыми семантическими факторами; две оси могут смешивать положение и радиус.

6. Демо: AE, VAE и схлопывание

Все значения ниже получены своим полным запуском lab08_demo.py в Engee, не взяты из архивных таблиц преподавателя. Диагностика на том же наборе disc, seed101.

β	Активные оси	Recon	Interp	Samples	R^2
0.0	не применяется	26.24324	22.30351	12.86172	0.93120
1.0	7	26.68584	22.67681	23.28100	0.88303
8.0	2	22.23962	22.38985	23.40695	0.94415

AE без KL не обучает согласование агрегированного латентного распределения с N(0,I); брать из него сэмплы по этому prior без проверки необоснованно. β>0 не гарантирует улучшения всех метрик - регуляризация имеет цену.

Без разогрева и с warmup10: реконструкция по пяти seed

Режим	101	102	103	104	105
без warmup	26.522	17.157	25.703	26.716	24.708
warmup10	26.686	26.877	25.643	26.883	25.770

Без разогрева худший seed 102 дал реконструкцию 17.1571 дБ; с warmup10 тот же seed дал 26.8770 дБ. Для ориентира средняя train-картинка, заново оценённая по данным ЛР8 на test, даёт 17.1707 дБ. В этой диагностике провал без warmup близок к тривиальному ответу, а разогрев его устранил в проверенной паре.

Это наблюдение согласуется с описанным в методичке схлопыванием. Сам по себе низкий PSNR не является исчерпывающим доказательством posterior collapse: для дополнительной серии сохранены метрики, но полные распределения каждого такого запуска отдельно не исследуются. Гарантии, что warmup исключает все будущие провалы, не даются. Новая сессия отдельно не проверялась.

Демо β=1 →8: собственная сводка

Метрика	A	s_A	B	Δ	|Δ|/s	>2s
recon	26.37189	0.61395	22.52873	-3.84317	6.26	да
interp	22.55258	0.48468	21.90205	-0.65053	1.34	нет
sample	23.24185	0.55578	23.20980	-0.03205	0.06	нет
r2	0.89948	0.02195	0.78554	-0.11394	5.19	да

7. Вывод и ограничения

Ожидание падения реконструкции более 1 дБ подтвердилось, ожидание падения среднего R^2 более 0,05 подтвердилось в данной серии. Менялось только d: 8→2; β, обучение, данные, seed и методы оценки сохранены.

recon: A=26.37189, B=23.22424, Δ=-3.14766; |Δ|/s_A=5.127. Класс по допуску 1.00: «ухудшение». Критерий 2s выполнен; согласуется с признаком превышения практического допуска.

interp: A=22.55258, B=22.97955, Δ=+0.42697; |Δ|/s_A=0.881. Класс по допуску 1.00: «нейтрально». Критерий 2s не выполнен; согласуется с признаком превышения практического допуска.

sample: A=23.24185, B=24.46666, Δ=+1.22481; |Δ|/s_A=2.204. Класс по допуску 1.00: «улучшение». Критерий 2s выполнен; согласуется с признаком превышения практического допуска.

r2: A=0.89948, B=0.64782, Δ=-0.25167; |Δ|/s_A=11.464. Класс по допуску 0.05: «ухудшение». Критерий 2s выполнен; согласуется с признаком превышения практического допуска.

Узкое место изменяет компромисс между точностью конкретной сцены и свойствами латентного пространства. Не требуется, чтобы все четыре метрики ухудшались одновременно. Среднее по seed показывает картину этой серии, а не универсальное свойство любого VAE.

Диагностика AE/VAE seed101: сэмплы AE β=0 имеют PSNR 12.8617, VAE β=1 - 23.2810. Это показывает практический смысл согласования с prior в этих условиях. Метрика ближайшего соседа не измеряет разнообразия и не исключает повторяющиеся сэмплы.

Для объяснения потерь используются R^2 каждого фактора и визуальный путь, но три порождающих фактора сами по себе не доказывают строгую минимальную размерность дискретных изображений. Линейная регрессия не равна полной оценке информации. Пять seed, один синтетический набор и одна архитектура не позволяют переносить результат на фотографии. Критерий 2s не является формальным тестом. CPU-обучение и время не обещают побитовой воспроизводимости; новый сеанс отдельно не проверен.

Чувствительность к удвоению допуска

recon: при допуске 2.000 класс «ухудшение». Критерий 2s не изменяется.

interp: при допуске 2.000 класс «нейтрально». Критерий 2s не изменяется.

sample: при допуске 2.000 класс «нейтрально». Критерий 2s не изменяется.

r2: при допуске 0.100 класс «ухудшение». Критерий 2s не изменяется.

Допуски основного вывода остаются исходными; удвоение - только анализ чувствительности, не подгонка результата.

8. Код и контрольные вопросы

Ключевой код Python. Полные исходники приложены, а фактическое выполнение и вывод сохранены в ноутбуке Engee.

```
N = 3
a_cfg, b_cfg = V.settings(V.FACTORS[(N-1) % 6])
result = V.variant_summary(N)
# Training: SSE over pixels + beta * KL
z = mu + torch.exp(0.5 * logvar) * epsilon
# Evaluation: deterministic reconstruction from mu
reconstruction = model.decode(model.encode(Xte))
```

1. Кодировщик VAE выдаёт μ и log σ² диагонального нормального распределения. Репараметризация z=μ+σ·ε, ε~N(0,I), отделяет случайность от обучаемых μ/σ и позволяет передавать градиент через выборку.

2. Потери - сумма квадратов реконструкции по пикселям и β·KL(q(z|x)||N(0,I)). Первое слагаемое сохраняет изображение; KL ограничивает передачу информации и согласует распределения с prior. Важна нормировка: замена суммы на среднее без изменения β меняет относительную силу регуляризации.

3. У обычного AE нет требования, чтобы его коды соответствовали N(0,I). Случайные нормальные точки могут оказаться вне области кодов, поэтому такая генерация без проверки необоснованна. Это не абсолютный запрет: требуется диагностика распределения и качества. В работе сравниваются реальные сэмплы AE и VAE.

4. Больший β усиливает регуляризацию и может ухудшить реконструкцию и отключить часть осей. Улучшение интерполяции и сэмплов не гарантируется; чрезмерная регуляризация может схлопнуть представление. Вывод делается по фактическому демо, а не только по интуиции о гладкости.

5. Смешивание пикселей даёт наложение исходных изображений и часто два полупрозрачных объекта. Интерполяция кодов с последующим декодированием может перемещать один объект и менять его свойства нелинейно. Это проверяется по истинному пути факторов и наличию двойных контуров.

6. Линейная интерполяция идёт по отрезку; сферическая использует угол между векторами и синусные веса, лучше сохраняет типичную норму при сопоставимых исходных длинах. Различия заметны для достаточно разных направлений; при почти коллинеарных кодах библиотека использует линейный путь. Slerp не гарантирует большего PSNR.

7. KL=-0,5·(1+log1-0,5²-1)=0,125 нат для одной оси.

8. При смене только способа интерполяции используются те же обученные веса и кодирование; реконструкция, сэмплы и R² не зависят от пути. Их неизменность - контроль. В нашем варианте3 меняется d, поэтому все четыре метрики могут изменяться.

9. По принятому критерию активна ось со средним KL>0,05 нат на test. Дополнительно смотрят std μ. Малый разброс μ и малый KL согласуются с неиспользуемой осью; один разброс не заменяет проверку распределения. Активность оси не доказывает её соответствия одному конкретному фактору.

10. Нужны исходные файлы и SHA-256, набор и seed данных, train/test и факторы, архитектура и d, β и warmup, seed обучения, эпохи/оптимизатор/lr/batch, dtype, CPU и число потоков, Python/PyTorch/NumPy/Engee, seed пар и сэмплов, t и температура, методы метрик и допуски. Побитовое совпадение и одинаковое время на другой машине не обещаются.

9. Паспорт, комплект и источники

Комплект: выполненный LR08_3.ngscript и копия Jupyter; этот PDF; основной, истинный и демонстрационный листы; журнал и снимок вывода Engee; исходные библиотеки; метрики, ошибки, латентные векторы, KL и регрессионные массивы; синтетические данные и факторы; веса seed101; паспорт и SHA-256; независимый проверяющий скрипт.

Независимая проверка пересчитывает четыре метрики, регрессию факторов, KL и активность, средние, s и допуски. Пиксельные ошибки и ближайшие соседи отдельно проверяются для первых восьми примеров seed101; вся серия проверяется по сохранённым ошибкам. Локальное повторное обучение и новый Engee-сеанс отдельно не выполнялись.

Индивидуальный вклад: гипотеза и допуски, подготовка среды Engee CPU, сохранение всех seed и диагностики, проверка R^2 по каждому фактору, независимый пересчёт, визуальный анализ и отчёт. Учебные исходники сохранены без изменения. Их лицензионный файл не приложен; неограниченное коммерческое использование не утверждается.

Источники

Приложенные методические указания ЛР8, 29 страниц; lab08_lib.py, lab08_demo.py, run_lr08.py; lab07_lib.py из ЛР7. Две копии lab08_lib в ZIP побитово одинаковы.

Kingma, Welling. Auto-Encoding Variational Bayes: https://arxiv.org/abs/1312.6114

Burgess et al. Understanding disentangling in beta-VAE: https://arxiv.org/abs/1804.03599

Документация PyTorch: https://docs.pytorch.org/docs/stable/nn.html

Синтетические сцены и веса получены с нуля в этой работе. Персональные данные, фотографии и внешние предобученные модели не использованы.